

Matriz de Costos y Justificación de Modelos por Tarea

Tipo de Tarea	Modelo Recomendado	Justificación Operativa	Costo Est. (Input/Output por 1M tokens)	Ahorro Est. vs. Flagship (GPT-4o / Claude Sonnet)
Generación de Borradores (El escenario de tu blueprint)	Cohere Command R (o GPT-4o-mini)	Balance ideal entre capacidad de razonamiento para la síntesis de tickets y costo reducido.	\$0.15 / \$0.60	~90% - 94% frente a modelos de gama alta.
Procesamiento Masivo en Lote (Historias/Logs)	OpenAI Batch API (GPT-4o-mini)	Para tareas diferidas que no requieren respuesta en tiempo real (SLA 24h).	\$0.075 / \$0.30 (50% descuento Batch)	~50% adicional sobre el costo ya reducido.
Análisis Ligero / Clasificación de Tickets	Cohere Command R7B	Tareas directas de bajo contexto (ej. categorizar en <i>Pendiente/Error</i>).	\$0.0375 / \$0.15	~98% respecto a modelos de razonamiento complejo.
Lectura Densa / Razonamiento Complejo	Claude 3.5 Sonnet / Cohere Command R+	Documentos largos, contratos o prompts de lógica crítica con instrucción compleja.	\$2.50 / \$10.00	Baseline de alta precisión (0% ahorro, solo para casos críticos).

Justificación Técnica del Flujo (Cohere Trial vs. Escalamiento)

- **Situación Actual (Cohere Plan Gratis / Trial Tier):**
 - **Costo Directo: \$0 USD** (hasta 100,000 llamadas API al mes / 5 llamadas por minuto).
 - **Uso en el Blueprint:** Ideal para la fase de prototipado y validación *Human-in-the-Loop* (HITL). No genera gastos mientras se afina el prompt y la estructura de Notion.

- **Riesgo:** Cuello de botella en volumen si se procesan muchos tickets simultáneos (límite de 5 RPM).
- **Estrategia de Optimización y Ahorro al Escalar (Pay-as-you-go):**
 1. **Selección del Modelo en el Escenario (cohere:chat):** Mantener un modelo balanceado como **Cohere Command R** en producción te permite escalar a un costo mínimo (\$0.15 / 1M tokens de entrada) garantizando que cada ticket procesado cueste una fracción de centavo (~\$0.0003 por propuesta).
 2. **Control de Outbound Tokens:** Como se documentó en el manual operativo, limitar la respuesta en el prompt a < 1,800 caracteres (aproximadamente 350-400 tokens) previene cobros innecesarios por respuestas extensas y evita el error 400 de Notion.
 3. **Delegación de Procesos Masivos:** Si en el futuro necesitas analizar un histórico de 10,000 tickets de Notion para generar reportes, derivar esa tarea específica a la **Batch API de OpenAI** mediante una ejecución programada nocturna reducirá los costos de entrada/salida a la mitad.